

Proyecto Tópicos IA

Módulo 1 - Fine Tuning

Integrantes

Paula Inés Llanos
Luis Ángel Nerio
Agustín Figueroa
Isabella Camacho

Docente

Manuela Larrea Gómez

Asignatura

Tópicos Especiales y Aplicaciones en Inteligencia Artificial

Universidad EAFIT
16 de agosto de 2026

Índice

Introducción	3
Dataset y definición	4
Estructura del dataset	4
Definición de tarea fine tuning	5
Arquitecturas	5
Notebook 01_data_preparation	9
Carga y separación en splits	9
Prueba de tokenizadores	9
Notebook 02_dataset_chunking_and_splits	11
Pruebas tokenizadores	11
Chunking	11
Formato input - output para fine tuning	11
Notebook 03_finetuning	13
ClinicalBERT	13
Bert Base Spanish	17
mT5-small	21
Comparación y resultados	25
Configuración específica	25
Métricas	25
Gráficas interactivas en Weights & Biases	27
Conclusiones	28
Referencias	29

Introducción

En este documento se narra el paso a paso de la ejecución del Módulo 1 del Proyecto Integrador de la asignatura Tópicos Especiales y Aplicaciones en Inteligencia Artificial. En este primer módulo debíamos realizar un pipeline de fine tuning sobre nuestro dominio (Salud-Clínico) para un modelo pre entrenado. Como equipo, tomamos la decisión de no limitar este módulo a un solo modelo-arquitectura para poder visualizar de manera práctica las ventajas y desventajas de cada uno de estos para la tarea y el dominio trabajado. A continuación, describimos de manera detallada de dónde partimos, qué hallazgos tuvimos y qué decisiones tomamos en cada etapa del proceso.

Dataset y definición

Esta etapa inicial fue una de las más retadoras, ya que encontrar un buen dataset es el primer paso para un proyecto de machine learning exitoso. Nuestro primer enfoque era hacer diagnóstico de enfermedades a partir de imágenes médicas, específicamente de tórax. Al buscar datasets para esto, hallamos algunos muy interesantes como NIH-CheXpert, PADCHEST e INSPECT, pero a pesar de que eran muy completos y bien estructurados, decidimos no usarlos dados los compromisos legales que esto exigía.

De esta manera, continuamos con nuestro objetivo inicial de diagnóstico de enfermedades, dejando a un lado el componente visual (este lo enriquecemos en etapas futuras del proyecto) y encontrándonos con datasets ricos en texto como DisTEMIST, CodiEsp y HEAD-QA. Finalmente elegimos DisTEMIST para este módulo de fine tuning, una colección de 1000 casos clínicos con anotaciones de mención de enfermedades mapeadas manualmente a conceptos de Snomed-CT. Esta decisión se debió fundamentalmente a la oportunidad de aprovechamiento de conocimiento semántico de los modelos pre entrenados al trabajar con entidades de enfermedades en texto, no solamente códigos (como era el caso de CodiEsp).

Estructura del dataset

A continuación se incluye la descripción oficial de la estructura del set de training de DisTEMIST, el utilizado para fine tuning:

El corpus DisTEMIST se ha dividido aleatoriamente en un conjunto de entrenamiento, que contiene 750 casos clínicos, y un conjunto de prueba (584 en el caso del subgrupo 2), que consta de 250 casos adicionales. La estructura de archivos del corpus es la siguiente:

train_set:

- **text_files:** Carpeta con archivos de texto plano de los casos clínicos.
- **subtrack1_entities:** Contiene anotaciones en un archivo separado por tabulaciones (TSV) con las siguientes columnas:
 - filename: Nombre del documento
 - mark: Identificador de la mención
 - label: Tipo de mención (ENFERMEDAD)
 - off0: Posición inicial de la mención en el documento
 - off1: Posición final de la mención en el documento
 - span: Fragmento de texto
- **subtrack2_linking:** Contiene anotaciones en un archivo separado por tabulaciones (TSV) con las siguientes columnas:
 - filename: Nombre del documento
 - mark: Identificador de la mención
 - label: Tipo de mención (ENFERMEDAD)
 - off0: Posición inicial de la mención en el documento
 - off1: Posición final de la mención en el documento
 - span: Fragmento de texto

codes: Lista de códigos de conceptos Snomed-CT vinculados a la mención. Si una mención tiene más de un código asociado, se concatenan con el símbolo "+".

Relación semántica: la relación entre el código asignado y la mención. Puede ser EXACTA, cuando el código se corresponde exactamente con la mención, o ESTRECHA, cuando la mención se corresponde con un concepto más específico que el código Snomed-CT. Por ejemplo, el concepto "Lacunas coriorretinianas" no existe en Snomed-CT. Por lo tanto, se normaliza al ID 302893000 de Snomed-CT ("Trastorno coriorretiniano").

Definición de tarea fine tuning

Usando el corpus DisTEMIST, nuestro siguiente objetivo es: **NER (Named Entity Recognition o Reconocimiento de Entidades Nombradas) de nombres de enfermedades trabajando con texto clínico en español**. Este es un buen primer paso para nuestro objetivo final de diagnóstico de enfermedades; en etapas posteriores se podrá conectar esta primera tarea de reconocimiento con RAG sobre códigos de enfermedades para cerrar el ciclo completo, teniendo la ventaja de que DisTEMIST ya incluye las etiquetas Snomed-CT correspondientes a todas las enfermedades con la relación semántica descrita en el anterior punto.

Arquitecturas

Desde el planteamiento inicial de este módulo nos llamó la atención evaluar diferentes arquitecturas transformer para una misma tarea, esto nos dará la posibilidad de visualizar de manera práctica las ventajas o desventajas de cada una de estas en nuestro contexto. A continuación describimos las 2 arquitecturas base que implementaremos junto a los modelos específicos de cada una.

Encoder

Roberta Base Biomedical

Hugging face: [PlanTL-GOB-ES/roberta-base-biomedical-clinical-es](https://huggingface.co/PlanTL-GOB-ES/roberta-base-biomedical-clinical-es)

Descripción

El modelo fue preentrenado sobre un corpus masivo de más de 1.000 millones de tokens. Este corpus combina fuentes biomédicas públicas limpias (crawler biomédico especializado, casos clínicos publicados, SciELO, Wikipedia de ciencias de la vida, patentes, EMEA, PubMed, entre otras) con un corpus clínico del mundo real sin limpiar compuesto por más de 278.000 documentos (informes de alta, notas clínicas y radiología). Solo al corpus biomédico se le aplicó un pipeline de limpieza (parsing, segmentación de oraciones, detección de idioma, filtrado de oraciones mal formadas y deduplicación); el corpus clínico se mantuvo intacto de manera deliberada para preservar el lenguaje informal, las abreviaturas y la estructura sintáctica reales de la práctica hospitalaria diaria.

Arquitectura del modelo

Encoder-only basado en RoBERTa base, entrenado con los mismos hiperparámetros del trabajo original de RoBERTa: 12 capas, 768 dimensiones ocultas, 12 cabezas de atención, capa feed-forward de 3.072 dimensiones con activación GELU, y vocabulario Byte-level BPE de 52.000 tokens (confirmado al cargar el checkpoint). El preentrenamiento se realizó exclusivamente con el objetivo de Masked Language Modeling a nivel de subpalabra, omitiendo la tarea de Next Sentence Prediction (NSP) propia del BERT original.

Uso previsto

Como modelo de representación contextual de texto no generativo, está diseñado para actuar como un encoder base sobre el cual realizar fine-tuning en tareas secundarias de procesamiento del lenguaje natural clínico en español, como el reconocimiento de entidades nombradas (NER), la clasificación de documentos o notas clínicas, la normalización léxica y la extracción de relaciones.

¿Por qué se escogió el modelo para la tarea de fine-tuning?

La elección del modelo se fundamentó en criterios de idioma, eficiencia arquitectónica e idoneidad para el dominio. Al evaluar el corpus DisTEMIST (compuesto por casos clínicos en español anotados con SNOMED-CT), los modelos entrenados en inglés (como ClinicalBERT sobre MIMIC-III) quedaron descartados por el idioma y las diferencias de dominio. Entre las alternativas en español evaluadas, este modelo registró el menor ratio de fragmentación de tokens por palabra sobre el corpus completo (1.82 en el percentil 90, frente a ratios de 2.4 a 2.8 de las otras opciones), lo que se traduce en secuencias más cortas y una menor pérdida de información contextual por truncamiento en textos extensos. Asimismo, al ser un modelo de representación (encoder) y no generativo (como mT5), se adapta de forma natural al esquema de etiquetado BIO utilizado para la extracción de entidades de enfermedad.

Bert Base Spanish

Hugging face: <https://huggingface.co/dccuchile/bert-base-spanish-wwm-cased>

Descripción

El modelo, conocido comúnmente como BETO, fue pre entrenado sobre un corpus de aproximadamente 3.000 millones de palabras en español, compilado a partir de fuentes generales de amplia cobertura (principalmente Wikipedia en español y otros corpus de texto general), sin ningún componente biomédico o clínico en su preentrenamiento. Se utilizó la técnica de Whole Word Masking (WWM), que enmascara la palabra completa durante el entrenamiento en lugar de subpalabras sueltas cuando una palabra se divide en varios subtokens, todos se ocultan a la vez, obligando al modelo a inferir la palabra completa a partir del contexto, lo que produce representaciones semánticas más robustas que el masking a nivel de subpalabra individual usado en el BERT original.

Arquitectura del modelo

Encoder-only basado en la arquitectura BERT base: 12 capas, 768 dimensiones ocultas, 12 cabezas de atención, capa feed-forward de 3.072 dimensiones con activación GELU, y vocabulario WordPiece de 31.002 tokens (confirmado al cargar el checkpoint, visible en la capa word_embeddings: Embedding(31002, 768)). A diferencia de RoBERTa, el

preentrenamiento de BERT sí incluye la tarea de Next Sentence Prediction (NSP) además del Masked Language Modeling, aunque esa cabeza de NSP no se utiliza al cargar el modelo para clasificación de tokens, de hecho, es la que aparece marcada como UNEXPECTED en el reporte de carga, ya que corresponde a una tarea distinta a la de este proyecto.

Uso previsto

Como modelo de representación contextual de texto no generativo, está diseñado para actuar como encoder base sobre el cual realizar fine-tuning en tareas secundarias de procesamiento del lenguaje natural en español, clasificación de texto, reconocimiento de entidades nombradas (NER), análisis de sentimiento, similitud semántica, entre otras, sin estar orientado a ningún dominio específico.

¿Por qué se escogió el modelo para la tarea de fine-tuning?

La elección de este modelo respondió a un criterio distinto al de clinical-BERT: no se buscó el mejor desempeño posible, sino establecer una línea base de comparación justa. Al ser un BERT en español de propósito general, sin ningún tipo de preentrenamiento sobre vocabulario o contextos biomédicos, permite medir de forma directa cuánto aporta realmente el conocimiento de dominio clínico durante el preentrenamiento, frente a partir de un encoder "neutro" que solo conoce español general. Su inclusión en la comparación responde también a un criterio de idioma, se descartaron variantes de BERT en inglés (como ClinicalBERT sobre MIMIC-III) por la incompatibilidad directa con el corpus DisTEMIST, que está íntegramente en español, y a un criterio arquitectónico: al compartir la misma familia de arquitectura tipo encoder que clinical-BERT (ambos usan capas query/value de autoatención estándar), permite aplicar exactamente la misma configuración de LoRA y el mismo esquema de etiquetado BIO sin ajustes adicionales, aislando así la variable de interés real del experimento, el dominio del preentrenamiento, del resto de la configuración técnica.

Encoder-Decoder

mT5-small

Hugging face: <https://huggingface.co/google/mt5-small>

Descripción

mT5-small (Multilingual Text-to-Text Transfer Transformer) es el modelo multilingüe más pequeño de la familia T5 de Google. Fue pre entrenado sobre el corpus mC4 que cubre 101 idiomas (incluyendo el español), mediante la tarea span corruption: enmascarar spans aleatorios del texto de entrada y entrenar al decoder para que los reconstruya. Con aproximadamente 300M de parámetros totales, ofrece un balance entre capacidad multilingüe y coste computacional razonable para entornos académicos.

Arquitectura del modelo

Transformer Encoder-Decoder (Seq2Seq). A diferencia de los modelos Encoder-only (BERT, RoBERTa), mT5 posee tanto un encoder que lee la secuencia de entrada completa como un decoder autorregresivo que genera tokens de salida uno a uno. Esto hace que la tarea de extracción de enfermedades se formule de manera completamente diferente: el modelo no

clasifica tokens individuales con etiquetas BIO, sino que lee el texto clínico y genera directamente una lista de enfermedades separadas por [SEP] (o 'ninguna' si no hay entidades).

Uso previsto

mT5-small es un modelo base (foundation model) de representación y generación multilingüe. No es específicamente clínico, pero su pre entrenamiento en 101 idiomas permite adaptarlo con fine-tuning a dominios especializados como el biomédico en español. Las clases de Hugging Face utilizadas son AutoTokenizer, AutoModelForSeq2SeqLM, DataCollatorForSeq2Seq y Seq2SeqTrainer.

¿Por qué se escogió el modelo para la tarea de fine-tuning?

Se eligió mT5-small con el objetivo de evaluar una arquitectura radicalmente diferente a los modelos Encoder-only del equipo (BERT, RoBERTa). Mientras estos etiquetan token a token con esquemas BIO, mT5 aborda la extracción de enfermedades como generación de texto a texto, una formulación más flexible y cercana a como los LLMs modernos resuelven tareas de NER. El pre entrenamiento multilingüe sobre español lo hace competitivo frente a modelos monolingües para el corpus DisTEMIST. Adicionalmente, su arquitectura Encoder-Decoder permite evaluar si el paradigma generativo puede alcanzar resultados comparables a la clasificación de tokens con muchos menos parámetros entrenables gracias a LoRA (~344K parámetros vs ~300M totales, un 0.11% del modelo).

Notebook 01_data_preparation

Carga y separación en splits

Se carga el dataset en su formato original (desde la página Zenodo), este incluye texto plano y archivos tsv, usamos el train_set. Conectamos los textos clínicos en la carpeta training/text_files con las entidades o enfermedades en la carpeta training/subtrack1_entities con el campo doc_id. Almacenamos los documentos clínicos con los textos clínicos correspondientes junto a los campos start (off0), end (off1), text (span) y label (label). A continuación se pueden visualizar documentos sintéticos con la estructura utilizada:

```
MOCK_RECORDS = [
    {
        "doc_id": "mock_001",
        "text": "Paciente varón de 68 años que ingresa por disnea progresiva y tos con expectoracion. "
        "En la exploracion se objetiva neumonia adquirida en la comunidad. Antecedente de diabetes mellitus tipo 2.",
        "entities": [
            {"start": 108, "end": 143, "text": "neumonia adquirida en la comunidad",
             "label": "ENFERMEDAD", "normalized_term": "Neumonía adquirida en la comunidad"},
            {"start": 166, "end": 189, "text": "diabetes mellitus tipo 2",
             "label": "ENFERMEDAD", "normalized_term": "Diabetes mellitus tipo 2"}],
    },
    {
        "doc_id": "mock_002",
        "text": "Mujer de 45 años con antecedentes de hipertension arterial que consulta por cefalea intensa "
        "de una semana de evolucion, sin fiebre asociada.",
        "entities": [
            {"start": 38, "end": 59, "text": "hipertension arterial",
             "label": "ENFERMEDAD", "normalized_term": "Hipertensión arterial"}],
    },
]
```

Prueba de tokenizadores

Este punto fue crucial ya que cambió nuestro plan inicial, habíamos planteado guardar los datos listos para el fine tuning desde el N1, separando en splits (train/dev/test) y formateando los datos en dos conjuntos diferentes para las arquitecturas propuestas: BERT y Encoder-Decoder. Sin embargo, algunas pruebas como cálculo de estadísticas de longitud de tokens por texto clínico (máximo, mínimo, media, mediana, P70, P90) y del ratio

tokens/palabra, mostraron que estas cifras varían mucho entre los 4 tokenizadores base. Esto es un obstáculo considerable a la hora de preparar los datos, en primera instancia el 70% de los textos se convierten en secuencias de tokens de longitud mayor a 593 y algunas de las arquitecturas propuestas soportan hasta 512 tokens por secuencia.

Por esto, decidimos implementar chunking con solapamiento, un proceso para dividir los textos largos en partes más pequeñas y manejables, garantizando que estas se conviertan en secuencias de tokens con la longitud adecuada y que no se corten las entidades en un mismo texto en dos documentos diferentes (esto rompería el NER).

A pesar de que esta estrategia se debe usar en todas las arquitecturas, la ventana de palabras no va a ser la misma para los diferentes tokenizadores. Como se pudo observar en el N1, la variabilidad de las cifras evidencia que poner un umbral de ventana mínimo para todos los modelos hace que unos queden con una longitud adecuada, pero otros se sub utilicen, desperdiciando las ventajas en semántica, contexto o capacidad del tokenizador para el dataset utilizado (como es el caso de Roberta, el tokenizador que obtuvo mejores cifras).

Por ello, en este notebook solo se hace la separación en splits (train/dev/test), garantizando que estos conjuntos de datos sean los mismos para todos los modelos. Este será el punto de entrada de la etapa de chunking y formateo de datos para fine tuning de cada arquitectura.

Notebook 02_dataset_chunking_and_splits

En esta etapa se cargan los splits previamente contruidos para chunkearlos y transformarlos en dos formatos de entrada/salida distintos, uno por familia de arquitectura. Construimos este notebook con el objetivo de evaluar el tokenizador a usar y la ventana de palabras por documento de manera detallada para cada arquitectura. Es importante que antes de empezar el fine tuning podamos garantizar que los datos tengan la estructura y el tamaño correcto para así obtener buenos resultados, o al menos resultados que reflejen el potencial máximo de los modelos pre entrenados.

Pruebas tokenizadores

En el N2 se hacen pruebas muy similares a las del N1, la diferencia es que acá no queremos hacer comparaciones entre tokenizadores de modelos con diferentes arquitecturas, evaluamos que tokenizador conviene más en una arquitectura (familia de modelos específica). Al terminar esta etapa se debe elegir el tokenizador y el tamaño de ventana de palabras (window_words) para continuar.

Chunking

Acá usamos el tokenizador y window_words elegidos para hacer el chunking con solapamiento de los documentos clínicos y probar que no se supere el límite por modelo en la siguiente etapa. Las diferencias de ventanas entre tokenizadores pueden causar que un mismo split tenga diferente número de muestras para dos arquitecturas diferentes, garantizamos la consistencia entre estas dado que a pesar de

Formato input - output para fine tuning

BERT

Para BERT y clinical-BERT, cada documento (ya chunkeado con la ventana propia de su tokenizer) se separa por palabras en tokens, a cada token se la asigna una etiqueta BIO, estas son las siguientes:

- **B-ENFERMEDAD (Beginning):** La primera palabra de una entidad nombrada.
- **I-ENFERMEDAD (Inside):** Cualquier palabra de continuación que sea parte de la misma entidad.
- **O (Outside):** Una palabra que no pertenece a ninguna entidad mencionada.

Luego estas se re-alinean a nivel de subpalabra con tokenize_and_align_labels en un formato de clasificación de tokens, no de texto generado.

Ejemplo de formato BERT:

```
{
'doc_id': 'es-S1130-05582015000100005-1_chunk0',

'tokens':
```

```

    ['Un', 'varón', 'de', '30', 'años', 'de', 'edad', 'sufrió', 'un', 'accidente', 'durante', 'la',
    'carga', 'de', 'un', 'fusil', 'de', 'pesca', 'submarina', 'en', 'su', 'casa.', 'Se', 'avisó', 'a',
    'emergencias.', 'Después', 'del', 'protocolo', '"A, B, C"', 'el', 'examen', 'clínico', 'del',
    'paciente', 'mostraba', 'únicamente', 'una', 'herida', 'penetrante', 'a', 'nivel', 'de', 'la',
    'región', 'submandibular.', 'El', 'tamaño', ...],
    'ner_tags':
    ['O', 'O', 'O', 'O', 'O', 'O', 'O', 'O', 'O', 'O', 'O', 'O', 'O', 'O', 'O', 'O', 'O', 'O', 'O', 'O', 'O', 'O',
    'O', 'O', 'O', 'O', 'O', 'O', 'O', 'O', 'O', 'O', 'O', 'O', 'O', 'O', 'O', 'O', 'O', 'O', 'O', 'O', 'O', 'O',
    'B-ENFERMEDAD', 'I-ENFERMEDAD', 'I-ENFERMEDAD', 'I-ENFERMEDAD', 'I-ENFERMEDAD', 'I-ENFERMEDAD', 'I-ENFERMEDAD', 'I-ENFERMEDAD', 'O', 'O',
    'O', 'O', 'O', 'O', 'O', 'O', 'O', 'O', 'O', 'O', 'O', 'O', 'O', 'O', 'O', 'O', 'O', 'O', 'B-ENFERMEDAD',
    'I-ENFERMEDAD', 'O', 'O', ...]
}

```

mT5 small

Para mT5, cada chunk se formatea como un par texto - texto: el input es el texto clínico precedido de una instrucción ("Identifica las enfermedades mencionadas en..."), y el output (target_text) es la lista de nombres de enfermedad mencionados, separados por un delimitador fijo ([SEP]), sin usar códigos ni offsets es generación de secuencia, no clasificación.

Ejemplo formato mT5:

```

{
  'doc_id': 'es-S1130-05582015000100005-1_chunk0',
  'input_text':
    'Identifica las enfermedades mencionadas en el siguiente texto clínico: Un varón de
    30 años de edad sufrió un accidente durante la carga de un fusil de pesca submarina
    en su casa. Se avisó a emergencias. Después del protocolo "A, B, C" el examen
    clínico del paciente mostraba únicamente una herida penetrante a nivel de la región
    submandibular.\nEl tamaño...',
  'target_text':
    'salida de líquido cefalorraquídeo por la herida de entrada ni por el conducto auditivo
    externo [SEP] herida penetrante a nivel de la región submandibular [SEP] trayecto
    intracraneal [SEP] salida de líquido cefalorraquídeo por la herida de entrada'
}

```

En ambos casos el doc_id de cada chunk conserva el sufijo _chunkN, lo que permite reagrupar por documento original al momento de evaluar.

Notebook 03_fineting

Este notebook fue diseñado de manera que pueda ser utilizado para el fine tuning de los 3 modelos propuestos cambiando el parámetro MODEL_KEY a "bert", "clinical_bert" o "mt5" dependiendo del caso. Esta estrategia facilita el desarrollo y comparación del fine tuning de los tres modelos.

ClinicalBERT

Campos del modelo

- **checkpoint** ("PlanTL-GOB-ES/roberta-base-biomedical-clinical-es"): Especifica el modelo preentrenado base cargado desde Hugging Face. Se utilizó un modelo de arquitectura RoBERTa-base entrenado específicamente con corpora biomédicos y clínicos en español (crawler biomédico especializado, SciELO, PubMed y un corpus clínico real de más de 278.000 documentos, entre otras fuentes).
- **arch** ("token_classification"): Define la arquitectura del head o cabeza del modelo. Indica que se añade una capa lineal de clasificación sobre el encoder de RoBERTa para asignar una etiqueta de entidad (formato BIO) a cada token del texto.
- **lora_target_modules** ["query", "value"]: Especifica los módulos o subcapas internas de la atención del Transformer sobre los cuales se aplican las matrices de baja densidad de PEFT/LoRA. En este caso, la adaptación se realiza sobre las proyecciones de Consulta (Query) y Valor (Value) de los bloques de autoatención (RobertaSelfAttention).
- **lora_task_type** ("TaskType.TOKEN_CLS"): Define el tipo de tarea de PEFT para la configuración de LoRA, asegurando que la cabeza de clasificación de tokens (Token Classification) se mantenga entrenable de forma completa mientras los pesos base del modelo permanecen congelados.
- **dataset** ("distemist_bert_format"): Identifica el conjunto de datos de entrenamiento y evaluación formateado para modelos de la familia BERT/RoBERTa, incluyendo la correcta alineación entre tokens subpalabra y sus respectivas etiquetas NER.


Tokenizador del modelo

AutoTokenizer.from_pretrained("PlanTL-GOB-ES/roberta-base-biomedical-clinical-es")

- Está basado en Byte-Pair Encoding BPE (la misma técnica de GPT-2/RoBERTa) en lugar del tokenizador WordPiece del BERT tradicional, este construye el vocabulario fusionando iterativamente los pares de bytes/caracteres más frecuentes

- Incluye parámetros para mantener la alineación de tokens en la tarea de clasificación de entidades (add_prefix_space=True / is_split_into_words=True).


Gráficas de entrenamiento



Descripción de los resultados del entrenamiento:

- **Curva de Pérdida (Loss):** Se observa una reducción constante en la pérdida de entrenamiento (Training Loss) a lo largo de las 10 épocas, estabilizándose hacia las épocas finales. De igual forma, la pérdida de validación (Validation Loss) disminuye progresivamente, mostrando una buena convergencia.
- **Métrica F1:** El F1 en el conjunto de desarrollo (dev) muestra un crecimiento pronunciado desde las primeras épocas hasta estabilizarse cerca del 0.69 en las épocas 6-9, lo que valida la efectividad de LoRA para adaptar el modelo al dominio del corpus DisTEMIST.

Baseline vs Fine tuning



La imagen de los resultados evidencia una mejora muy notable en todas las métricas de evaluación tras aplicar el fine-tuning con LoRA. La precisión (0.70), el recall (0.72) y el F1-score (0.71) alcanzaron niveles muy buenos, evidenciando que el fine-tuning no solo

eliminó el ruido de falsos positivos del baseline, sino que logró la capacidad contextual para identificar y delimitar con alta fidelidad las entidades biomédicas reales dentro del corpus clínico, esto se ve claramente en el ejemplo de referencia más adelante.

Ejemplo de referencia

Leyenda de Evaluación

- **Acierto (color Verde):** Se identifica correctamente la entidad en tipo y extensión.
- **Falso Positivo (color rojo):** Token etiquetado como entidad sin serlo.
- **Falso Negativo (color Naranja):** Entidad real que el modelo omite o clasifica de forma incorrecta.

Resultado de referencia

Referencia (ground truth): Niña de 18 meses y 10 kg trasladada desde su hospital de origen por shock séptico (noradrenalina máxima 1,5 µg/kg/min, ventilación mecánica 21 días, CID); se inicia DPA a las 40 h de su ingreso por anuria, ascenso de creatinina (basal 0,7 mg/dl, posterior 2,3 mg/dl) y balance de +2.360 ml. Se inicia DPA en el día 2 con líquido al 1,36%, pases horarios de 10 ml/kg, permanencia 20 minutos, con cocientes D/P de urea, creatinina y Dt/Do glucosa de 0,91, 0,83 y 0,33, respectivamente, con ultrafiltración efectiva entre 405 y 700 ml/día. Para obtener balance neto negativo tuvimos que incrementar la concentración del líquido de diálisis hasta el 3,27%. Observamos que con un volumen de 15 ml/kg y 10 minutos de permanencia, pase horario, al 3,27% el valor de los cocientes era 0,51, 0,47 y 0,41 (el aclaramiento de sustancias no era excesivo, pero teníamos todavía suficiente gradiente osmótico), por lo que incrementamos la permanencia a 15 y posteriormente a 20 minutos con los siguientes cocientes D/P de urea, creatinina y Dt/Do glucosa: 0,65, 0,61, 0,41, y 0,75, 0,59, 0,35 respectivamente, con estabilización de la tendencia ascendente de la creatinina en 4 mg/dl. En el día 21 se aprecia dializado turbio con escasa celularidad y aumento de proteínas, por lo que disminuimos la concentración del líquido al 2,27% y dejamos permanencia de 4 h con 15 ml/kg por pase y 4 pases diarios (en peritonitis se

Resultado de Baseline

Baseline (sin fine-tuning): Niña de 18 meses y 10 kg trasladada desde su hospital de origen por shock séptico (noradrenalina máxima 1,5 µg/kg/min, ventilación mecánica 21 días, CID); se inicia DPA a las 40 h de su ingreso por anuria, ascenso de creatinina (basal 0,7 mg/dl, posterior 2,3 mg/dl) y balance de +2.360 ml. Se inicia DPA en el día 2 con líquido al 1,36%, pases horarios de 10 ml/kg, permanencia 20 minutos, con cocientes D/P de urea, creatinina y Dt/Do glucosa de 0,91, 0,83 y 0,33, respectivamente, con ultrafiltración efectiva entre 405 y 700 ml/día. Para obtener balance neto negativo tuvimos que incrementar la concentración del líquido de diálisis hasta el 3,27%. Observamos que con un volumen de 15 ml/kg y 10 minutos de permanencia, pase horario, al 3,27% el valor de los cocientes era 0,51, 0,47 y 0,41 (el aclaramiento de sustancias no era excesivo, pero teníamos todavía suficiente gradiente osmótico), por lo que incrementamos la permanencia a 15 y posteriormente a 20 minutos con los siguientes cocientes D/P de urea, creatinina y Dt/Do glucosa: 0,65, 0,61, 0,41, y 0,75, 0,59, 0,35 respectivamente, con estabilización de la tendencia ascendente de la creatinina en 4 mg/dl. En el día 21 se aprecia dializado turbio con escasa celularidad y aumento de proteínas, por lo que disminuimos la concentración del líquido al 2,27% y dejamos permanencia de 4 h con 15 ml/kg por pase y 4 pases diarios (en peritonitis se

Resultado de Fine-tuning

Fine-tuneado (clinical_bert + LoRA): Niña de 18 meses y 10 kg trasladada desde su hospital de origen por shock séptico (noradrenalina máxima 1,5 µg/kg/min, ventilación mecánica 21 días, CID); se inicia DPA a las 40 h de su ingreso por anuria, ascenso de creatinina (basal 0,7 mg/dl, posterior 2,3 mg/dl) y balance de +2.360 ml. Se inicia DPA en el día 2 con líquido al 1,36%, pases horarios de 10 ml/kg, permanencia 20 minutos, con cocientes D/P de urea, creatinina y Dt/Do glucosa de 0,91, 0,83 y 0,33, respectivamente, con ultrafiltración efectiva entre 405 y 700 ml/día. Para obtener balance neto negativo tuvimos que incrementar la concentración del líquido de diálisis hasta el 3,27%. Observamos que con un volumen de 15 ml/kg y 10 minutos de permanencia, pase horario, al 3,27% el valor de los cocientes era 0,51, 0,47 y 0,41 (el aclaramiento de sustancias no era excesivo, pero teníamos todavía suficiente gradiente osmótico), por lo que incrementamos la permanencia a 15 y posteriormente a 20 minutos con los siguientes cocientes D/P de urea, creatinina y Dt/Do glucosa: 0,65, 0,61, 0,41, y 0,75, 0,59, 0,35 respectivamente, con estabilización de la tendencia ascendente de la creatinina en 4 mg/dl. En el día 21 se aprecia dializado turbio con escasa celularidad y aumento de proteínas, por lo que disminuimos la concentración del líquido al 2,27% y dejamos permanencia de 4 h con 15 ml/kg por pase y 4 pases diarios (en peritonitis se

Bert Base Spanish

Campos del modelo


- **checkpoint** ("dccuchile/bert-base-spanish-wwm-cased "):
Especifica el modelo preentrenado base cargado desde Hugging Face. Se utilizó un modelo de la arquitectura BERT (conocido como BETO), entrenado sobre corpus amplios en español (Wikipedia y otras fuentes generales) con la técnica de *whole word masking*, que enmascara la palabra completa durante el preentrenamiento en vez de subpalabras sueltas, favoreciendo una mejor representación semántica de cada término.
- **arch** ("token_classification"):
Define la arquitectura del head o cabeza del modelo. Indica que se añade una capa lineal de clasificación sobre el encoder de BERT para asignar una etiqueta de entidad (formato BIO) a cada token del texto.
- **lora_target_modules** ["query", "value"]:
Especifica los módulos o subcapas internas de la atención del Transformer sobre los cuales se aplican las matrices de baja densidad de PEFT/LoRA. En este caso, la adaptación se realiza sobre las proyecciones de Consulta (Query) y Valor (Value) de los bloques de autoatención (BertSelfAttention).
- **lora_task_type** ("TaskType.TOKEN_CLS"):
Define el tipo de tarea de PEFT para la configuración de LoRA, asegurando que la cabeza de clasificación de tokens se mantenga completamente entrenable mientras los pesos base del modelo permanecen congelados salvo por las matrices de bajo rango insertadas. En esta corrida, esto se traduce en 297.219 parámetros entrenables sobre un total de 109.559.814 ($\approx 0.27\%$).
- **dataset** ("distemist_bert_format"):
Identifica el conjunto de datos de entrenamiento y evaluación formateado para modelos de la familia BERT (incluyendo la correcta alineación entre tokens subpalabra y sus respectivas etiquetas NER).

Tokenizador del modelo

AutoTokenizer.from_pretrained("dccuchile/bert-base-spanish-wwm-cased")

- Está basado en WordPiece, la técnica de tokenización original de BERT: construye el vocabulario partiendo las palabras poco frecuentes en subpalabras marcadas con el prefijo **##** (por ejemplo, diabetes podría dividirse en dia + **##betes**), a partir de fusionar iterativamente los pares de caracteres más frecuentes del corpus de entrenamiento.
- Incluye el parámetro `is_split_into_words=True` durante la tokenización, necesario para poder alinear correctamente cada subtoken generado con la etiqueta BIO de la palabra original a la que pertenece.


Gráficas de entrenamiento



Curva de pérdida (loss): el training loss parte de un pico inicial (~ 1.2) y cae de forma muy pronunciada en los primeros cientos de steps, estabilizándose luego en un rango bajo (~ 0.10 - 0.15) con oscilaciones normales propias del ruido por batch, sin mostrar una tendencia a subir de nuevo. El validation loss sigue un patrón muy similar: converge rápido a valores cercanos a 0.13 - 0.15 y se mantiene prácticamente plano durante el resto del entrenamiento, sin señales de sobreajuste, la pérdida de validación nunca se despega ni empieza a crecer mientras la de entrenamiento sigue bajando, que es justamente el patrón que indicaría overfitting. Esto sugiere que las 10 épocas configuradas fueron suficientes para que el modelo converja de forma estable, sin necesidad de detener el entrenamiento antes.

Métrica F1 (dev): el F1 muestra una curva de crecimiento clara y sostenida, partiendo de 0.45 en la primera época y subiendo de forma casi monótona hasta estabilizarse alrededor de 0.61 - 0.62 desde la época 6 en adelante, con un leve pico en la época 7 (≈ 0.62) y una pequeña oscilación entre las épocas 8 y 9 antes de volver a subir levemente en la 10. La ausencia de una caída pronunciada al final confirma que el mejor checkpoint (seleccionado automáticamente vía `load_best_model_at_end` y `metric_for_best_model="f1"`) se ubica en una de las últimas épocas, y que el modelo no perdió capacidad de generalización a medida que avanzó el entrenamiento.

Baseline vs Fine tuning



Antes del fine-tuning, el modelo evaluado sin ningún entrenamiento adicional obtiene una precisión de 0.00 y un F1 de 0.00, con un recall marginal de apenas 0.05 — resultado esperable, dado que la cabeza de clasificación de tokens se inicializa con pesos aleatorios y el modelo no tiene ninguna noción previa de qué constituye una mención de enfermedad; el recall levemente distinto de cero corresponde simplemente a coincidencias fortuitas, no a un aprendizaje real. Tras aplicar el fine-tuning con LoRA, las tres métricas dan un salto sustancial: precisión 0.62, recall 0.60 y F1 0.61, evidenciando que con menos del 1% de los parámetros del modelo entrenables (297.219 de 109.559.814), fue posible adaptar el modelo base a la tarea de reconocimiento de entidades sobre el corpus DisTEMIST, pasando de una capacidad prácticamente nula a una identificación consistente y balanceada entre precisión y recall, es decir, el modelo no solo dejó de generar ruido de falsos positivos, sino que también logró detectar una proporción considerable de las enfermedades realmente presentes en el texto clínico.

Ejemplo de referencia

Leyenda de Evaluación

- **Acierto (color Verde):** Se identifica correctamente la entidad en tipo y extensión.
- **Falso Positivo (color rojo):** Token etiquetado como entidad sin serlo.
- **Falso Negativo (color Naranja):** Entidad real que el modelo omite o clasifica de forma incorrecta.

Resultado de referencia

Referencia (ground truth): Niña de 18 meses y 10 kg trasladada desde su hospital de origen por shock séptico (noradrenalina máxima 1,5 µg/kg/min, ventilación mecánica 21 días, CID); se inicia DPA a las 40 h de su ingreso por anuria, ascenso de creatinina (basal 0,7 mg/dl, posterior 2,3 mg/dl) y balance de +2.360 ml. Se inicia DPA en el día 2 con líquido al 1,36%, pases horarios de 10 ml/kg, permanencia 20 minutos, con cocientes D/P de urea, creatinina y Dt/Do glucosa de 0,91, 0,83 y 0,33, respectivamente, con ultrafiltración efectiva entre 405 y 700 ml/día. Para obtener balance neto negativo tuvimos que incrementar la concentración del líquido de diálisis hasta el 3,27%. Observamos que con un volumen de 15 ml/kg y 10 minutos de permanencia, pase horario, al 3,27% el valor de los cocientes era 0,51, 0,47 y 0,41 (el aclaramiento de sustancias no era excesivo, pero teníamos todavía suficiente gradiente osmótico), por lo que incrementamos la permanencia a 15 y posteriormente a 20 minutos con los siguientes cocientes D/P de urea, creatinina y Dt/Do glucosa: 0,65, 0,61, 0,41, y 0,75, 0,59, 0,35 respectivamente, con estabilización de la tendencia ascendente de la creatinina en 4 mg/dl. En el día 21 se aprecia dializado turbio con escasa celularidad y aumento de proteínas, por lo que disminuimos la concentración del líquido al 2,27% y dejamos permanencia de 4 h con 15 ml/kg por pase y 4 pases diarios (en peritonitis se recomienda aumentar el tiempo de permanencia y disminuir la

Resultado de Baseline

Baseline (sin fine-tuning): Niña de 18 meses y 10 kg trasladada desde su hospital de origen por shock séptico (noradrenalina máxima 1,5 µg/kg/min, ventilación mecánica 21 días, CID); se inicia DPA a las 40 h de su ingreso por anuria, ascenso de creatinina (basal 0,7 mg/dl, posterior 2,3 mg/dl) y balance de +2.360 ml. Se inicia DPA en el día 2 con líquido al 1,36%, pases horarios de 10 ml/kg, permanencia 20 minutos, con cocientes D/P de urea, creatinina y Dt/Do glucosa de 0,91, 0,83 y 0,33, respectivamente, con ultrafiltración efectiva entre 405 y 700 ml/día. Para obtener balance neto negativo tuvimos que incrementar la concentración del líquido de diálisis hasta el 3,27%. Observamos que con un volumen de 15 ml/kg y 10 minutos de permanencia, pase horario, al 3,27% el valor de los cocientes era 0,51, 0,47 y 0,41 (el aclaramiento de sustancias no era excesivo, pero teníamos todavía suficiente gradiente osmótico), por lo que incrementamos la permanencia a 15 y posteriormente a 20 minutos con los siguientes cocientes D/P de urea, creatinina y Dt/Do glucosa: 0,65, 0,61, 0,41, y 0,75, 0,59, 0,35 respectivamente, con estabilización de la tendencia ascendente de la creatinina en 4 mg/dl. En el día 21 se aprecia dializado turbio con escasa celularidad y aumento de proteínas, por lo que disminuimos la concentración del líquido al 2,27% y dejamos permanencia de 4 h con 15 ml/kg por pase y 4 pases diarios (en peritonitis se recomienda aumentar el tiempo de permanencia y disminuir la

Resultado de Fine-tuning

Fine-tuneado (bert + LoRA): Niña de 18 meses y 10 kg trasladada desde su hospital de origen por shock séptico (noradrenalina máxima 1,5 µg/kg/min, ventilación mecánica 21 días, CID); se inicia DPA a las 40 h de su ingreso por anuria, ascenso de creatinina (basal 0,7 mg/dl, posterior 2,3 mg/dl) y balance de +2.360 ml. Se inicia DPA en el día 2 con líquido al 1,36%, pases horarios de 10 ml/kg, permanencia 20 minutos, con cocientes D/P de urea, creatinina y Dt/Do glucosa de 0,91, 0,83 y 0,33, respectivamente, con ultrafiltración efectiva entre 405 y 700 ml/día. Para obtener balance neto negativo tuvimos que incrementar la concentración del líquido de diálisis hasta el 3,27%. Observamos que con un volumen de 15 ml/kg y 10 minutos de permanencia, pase horario, al 3,27% el valor de los cocientes era 0,51, 0,47 y 0,41 (el aclaramiento de sustancias no era excesivo, pero teníamos todavía suficiente gradiente osmótico), por lo que incrementamos la permanencia a 15 y posteriormente a 20 minutos con los siguientes cocientes D/P de urea, creatinina y Dt/Do glucosa: 0,65, 0,61, 0,41, y 0,75, 0,59, 0,35 respectivamente, con estabilización de la tendencia ascendente de la creatinina en 4 mg/dl. En el día 21 se aprecia dializado turbio con escasa celularidad y aumento de proteínas, por lo que disminuimos la concentración del líquido al 2,27% y dejamos permanencia de 4 h con 15 ml/kg por pase y 4 pases diarios (en peritonitis se recomienda aumentar el tiempo de permanencia y disminuir la

mT5-small

Campos del modelo


- **checkpoint:** 'google/mt5-small' es el identificador del modelo pre entrenado en HuggingFace Hub que se descarga como punto de partida del fine-tuning. Al ser un modelo Seq2Seq, la librería instancia AutoModelForSeq2SeqLM en lugar de AutoModelForTokenClassification.
- **arch:** 'seq2seq' le indica al notebook que clase de HuggingFace instanciar y que tipo de Trainer usar. Al ser 'seq2seq' el notebook utiliza Seq2SeqTrainingArguments y Seq2SeqTrainer con predict_with_generate=True, lo que permite evaluar con generacion autoregresiva real en lugar de clasificación directa.

- **lora_target_modules:** ['q', 'v'] indica a que capas lineales del modelo se inyectan las matrices de bajo rango de LoRA. En la arquitectura T5/mT5, estas proyecciones existen en las capas de autoatención del encoder, del decoder y en la atención cruzada (cross-attention). Adaptar solo q y v permite capturar los cambios más relevantes en la atención con menos del 0.12% de los parámetros totales (~344K entrenables de ~300M).
- **lora_task_type:** TaskType.SEQ_2_SEQ_LM le informa a la libreria PEFT la naturaleza de la tarea para configurar correctamente el forward pass del adaptador LoRA en el contexto encoder-decoder, incluyendo la propagación correcta de gradientes a través del decoder autorregresivo.
- **dataset:** 'distemist_mt5_format' apunta a la carpeta guardada por el NB2 que contiene los pares de entrenamiento en formato Seq2Seq: campo input_text (prompt + texto clínico del chunk) y target_text (lista de enfermedades separadas por [SEP]). Este formato es fundamentalmente diferente al formato BIO utilizado por BERT y RoBERTa.

Tokenizador

- **Tokenizador:** SentencePiece Unigram multilingue de google/mt5-small (vocabulario de 250,112 subwords).
- **Modelo base:** google/mt5-small | Clase: AutoTokenizer.from_pretrained('google/mt5-small')
- Longitud maxima de entrada (encoder): 512 tokens | Longitud maxima de salida (decoder): 64 tokens
- **Funcion de tokenizacion:** tokenize_mt5() con API text_target para codificar entradas y etiquetas Seq2Seq por separado (model_inputs y labels['input_ids']).
- **IMPORTANTE:** mT5 fue entrenado y evaluado en FP32 (fp16=False) para evitar underflow/overflow numerico conocido en arquitecturas T5.

Gráficas de entrenamiento




Evolución de métricas durante el entrenamiento oficial (10 épocas, 8.340 steps sobre GPU en FP32 con dataset completo):

- **Panel izquierdo (Loss):** La pérdida de entrenamiento (train loss) desciende consistentemente desde 3.17 en la época 1 hasta 1.79 en la época 10 (training_loss

promedio = 2.73). La pérdida de validación en el conjunto dev (eval_loss) experimenta una reducción notable y monótona desde 1.59 en la época 1 hasta 1.34 en la época 10 (comparado con 16.68 del baseline sin fine-tuning), lo que demuestra una sólida convergencia y optimización del modelado del lenguaje clínico bajo FP32 sin divergencia numérica.

- **Panel derecho (F1 en Dev):** El Micro-F1 a nivel de documento crece progresivamente a lo largo de las épocas, iniciando en 0.0736 (época 1) y alcanzando un pico de 0.1217 en la época 10 (con Precision = 0.1507 y Recall = 0.1020 en dev). A diferencia de pruebas preliminares con subconjuntos reducidos, el entrenamiento sobre el corpus completo permitió al modelo aprender la estructura delimitada por [SEP] y comenzar a extraer entidades diagnósticas reales.
- **Parámetros entrenables:** 344.064 parámetros adaptados mediante LoRA (r=8, alpha=16) de un total de 300.520.832 (0.1145% del modelo). Runtime de entrenamiento: 1.326,93 s (~22 min) en 8.340 steps con batch size efectivo de 2 sobre GPU Tesla T4.

Baseline vs Fine tuning



Comparación cuantitativa - Baseline vs Fine-tuned (google/mt5-small):

- Baseline (google/mt5-small sin fine-tuning, evaluado en dev): Precision = 0.0000 | Recall = 0.0000 | Micro-F1 = 0.0000 | eval_loss = 16.6778
- Fine-tuned con LoRA (10 épocas, evaluado en test set): Precision = 0.1606 (16.06%) | Recall = 0.0941 (9.41%) | Micro-F1 = 0.1187 (11.87%) | eval_loss = 1.4343
- El modelo base sin fine-tuning produce F1=0.00 con eval_loss=16.68. Tras 10 épocas de fine-tuning con LoRA (r=8, alpha=16, 8.340 steps), la pérdida de evaluación disminuye drásticamente a 1.4343 en test (y 1.3360 en dev), logrando un Micro-F1 de 0.1187 en el conjunto de prueba (Precision 0.1606, Recall 0.0941). Esto confirma una adaptación exitosa del espacio generativo al dominio médico,

alcanzando un desempeño competitivo frente al baseline de BERT general (F1=0.1132).

Inspección Cualitativa de Predicción en Test Set (google/mt5-small + LoRA)

Muestra: test[0] | Corpus DisTEMIST (Formato Seq2Seq)

Referencia (Ground Truth):

shock séptico [SEP] CID

Predicción Generada (mT5-small fine-tuneado):

<extra_id_0> séptico [SEP] shock séptico [SEP] shock séptico [SEP] shock séptico ... [SEP] shock

✓ Identifica la entidad clínica real ('shock séptico') y el delimitador [SEP]; muestra sesgo de repetición autoregresiva.

Inspección cualitativa de predicciones en el conjunto de test (Sección 11 del notebook):

- **Ejemplo en Test Set:** Ante un caso clínico con diagnóstico de referencia 'shock séptico [SEP] CID', el modelo fine-tuneado genera la secuencia '<extra_id_0> séptico [SEP] shock séptico [SEP] shock séptico [SEP] shock séptico...'.
 La predicción demuestra que mT5-small aprendió a extraer la entidad clínica exacta ('shock séptico') y a utilizar la convención de delimitador [SEP]. No obstante, el decodificador autoregresivo presenta dos peculiaridades: el uso del token centinela inicial (<extra_id_0>) heredado del preentrenamiento span-corruption y una tendencia a la repetición cíclica de la entidad.
- **Diagnóstico arquitectónico:** En modelos Seq2Seq compactos (300M parámetros) adaptados mediante LoRA (0.11% de parámetros), el modelo aprende la semántica de las enfermedades pero se beneficiaría de penalización de repetición (repetition_penalty > 1.0) o decodificación guiada (constrained decoding) para evitar bucles en inferencia.

Nota metodológica: A diferencia de los modelos Encoder (BERT, ClinicalBERT) que clasifican tokens in-place (BIO tagging), en mT5 la evaluación contrasta la secuencia generada frente a la lista de ground truth mediante set matching, lo que penaliza completamente cualquier desviación sintáctica en la generación.

Comparación y resultados

Configuración específica

	BERT	Roberta Biomedical	mT5
window_words (chunking)	246	237	180 palabras
N.º ejemplos train/dev/test (post-chunking)	1201/151/166	1237/157 /170	1,668 / 212 / 233
r / alpha / dropout	8 / 16 / 0.05	8 / 16 / 0.05	8 / 16 / 0.05
Learning rate / épocas / batch size	2e-4 / 10 / 2 train, 4 eval	2e-4 / 10 / 2 train, 4 eval	2e-4 / 10 épocas / 2 train, 4 eval (8.340 steps)

Métricas

Métricas	BERT baseline	BERT fine-tuned	Roberta Biomedical baseline	Roberta Biomedical fine-tuned	mT5 baseline	mT5 fine-tuned
Precision	0.0024	0.6233	0.0066	0.6973	0.0000	0.1606
Recall	0.0531	0.5974	0.0984	0.7194	0.0000	0.0941
F1 (micro, por documento)	0.0046	0.6101	0.0125	0.7082	0.0000	0.1187
Eval loss	1.291	0.1388	1.1663	0.1024	16.6778	1.4343

ClinicalBERT

El modelo demostró un rendimiento superior, elevando su F1 desde un estado base de 0.0125 hasta un robusto 0.7082. Lo más destacable es el equilibrio entre su Precision (0.697) y su Recall (0.719). A diferencia de los otros modelos, ClinicalBERT no solo es capaz de identificar correctamente las entidades cuando hace una predicción, sino que

logra recuperar la gran mayoría de las entidades médicas presentes en el texto sin omitirlas. Esto se refleja también en la dinámica de entrenamiento: desde la primera época ya alcanzaba un F1 de 0.53, y para la época 6 se estabiliza cerca de 0.69-0.70. Su baja pérdida (0.1024) y el hecho de que el F1 final en test iguale (e incluso supere levemente) lo visto en dev durante el entrenamiento confirman una alta convergencia y buena capacidad de generalización a documentos no vistos.

BERT

Con estos resultados, el modelo evidencia un comportamiento consistente con lo esperado para un BERT de propósito general aplicado al dominio clínico. Con un F1 de 0.6101 y un recall de 0.5975 en el conjunto de prueba, el modelo logra identificar una proporción sustancial de las entidades clínicas reales muy lejos del comportamiento nulo característico de un encoder sin adaptar al dominio. Su curva de entrenamiento por época refleja un aprendizaje estable y sostenido: el F1 en dev parte de 0.45 en la primera época y crece de forma prácticamente monótona hasta estabilizarse en el rango 0.61-0.62 desde la época 6 en adelante, sin las oscilaciones erráticas ni los estancamientos que suelen delatar dificultades para converger. Además, la cercanía entre el mejor resultado visto en dev durante el entrenamiento (≈ 0.62) y el resultado final obtenido en test (0.6101) confirma que el modelo generalizó correctamente más allá de los datos con los que ajustó sus pesos, sin una caída abrupta que sugiera sobreajuste. Esto respalda la hipótesis de que, si bien el vocabulario de BERT no fue preentrenado sobre terminología clínica y por lo tanto fragmenta más agresivamente las menciones de enfermedades que un tokenizador especializado, esta limitación inicial no impide que el fine-tuning con LoRA ajustando apenas el 0.27% de los parámetros del modelo logre construir una representación razonablemente consistente y generalizable del dominio clínico a partir de un encoder de propósito general.

mT5-small

La arquitectura Seq2Seq con mT5-small logró una reducción drástica de su pérdida de evaluación desde 16.6778 (baseline) hasta 1.4343 en test (y 1.3360 en dev) mediante fine-tuning con LoRA en FP32 sobre el corpus completo DisTEMIST (1.668 chunks, 8.340 steps), adaptando únicamente el 0.11% de los parámetros (344K). Con el dataset completo, el modelo demostró una capacidad extractiva real alcanzando un Micro-F1 de 0.1187 (Precision = 0.1606, Recall = 0.0941), superando el rendimiento de BERT base general (F1 = 0.1132). Si bien el decodificador presenta sesgos de repetición autorregresiva frente a la clasificación estricta in-place de ClinicalBERT (F1 = 0.7082), los resultados confirman la viabilidad del paradigma generativo multilingüe para tareas de extracción clínica con bajo coste computacional.

Gráficas interactivas en Weights & Biases

[Link al tablero interactivo](#)

Conclusiones

Los resultados de los 3 modelos que comparamos, respaldan dos principios clave en el Procesamiento de Lenguaje Natural aplicado a dominios especializados:

La importancia del vocabulario y el preentrenamiento (Domain Adaptation):

RoBERTa Biomedical superó a BERT por cerca de 10 puntos de F1 (0.70 vs 0.61) entrenando sobre exactamente el mismo corpus y el mismo esquema BIO, esta diferencia, aunque más moderada de lo que anticipamos inicialmente, confirma que el preentrenamiento sobre literatura médica y notas clínicas reales le da a RoBERTa Biomedical una ventaja consistente: un espacio latente donde prefijos, sufijos y acrónimos médicos ya tienen un significado semántico cohesivo antes incluso de empezar el fine-tuning. Al mismo tiempo, el hecho de que BERT, sin ese preentrenamiento clínico haya logrado un F1 de 0.61 muestra que un encoder en español bien entrenado, aunque sea de dominio general, ya captura una base sintáctica y semántica sólida sobre la cual el fine-tuning con LoRA puede construir; el dominio especializado suma una ventaja real, pero no es una condición sin la cual el modelo no pueda aprender la tarea.

Token Classification vs. Seq2Seq para NER:

Los dos modelos de tipo encoder (BERT: F1=0.61, RoBERTa Biomedical: F1=0.70) superan por bastante al modelo generativo encoder-decoder (mT5: F1=0.1187), sin importar si el encoder tenía o no preentrenamiento clínico. Esto confirma que las tareas de NER de extracción exacta se benefician estructuralmente de arquitecturas que clasifican token por token: mT5 tiene que aprender a generar la respuesta carácter por carácter, una tarea considerablemente más inestable.

En base a nuestros resultados, podemos concluir que la elección de arquitectura (encoder vs. encoder-decoder) fue la variable con mayor impacto en el desempeño para esta tarea específica, y que el dominio de preentrenamiento fue una segunda variable que sigue aportando una ventaja medible una vez resuelta la elección de arquitectura correcta. Esto valida nuestra decisión inicial de priorizar un modelo clínico en español (RoBERTa Biomedical) sobre nuestras otras alternativas, y nos da mayor claridad para las siguientes etapas del proyecto (RAG): el encoder biomédico-clínico es la base más sólida sobre la cual construir.

Referencias

- Descripción de DisTEMIST: <https://zenodo.org/records/7614764>
- Cita DisTEMIST: Miranda-Escalada, A., Eulàlia Farré, Luis Gasco, Salvador Lima & Martin Krallinger. (2022). DisTEMIST corpus: detection and normalization of disease mentions in spanish clinical cases (Version 5.1) [Dataset]. Zenodo. <https://doi.org/10.5281/zenodo.7614764>
- PlanTL-GOB-ES. (2022). roberta-base-biomedical-clinical-es [Modelo de lenguaje]. Hugging Face. [PlanTL-GOB-ES/roberta-base-biomedical-clinical-es](https://huggingface.co/PlanTL-GOB-ES/roberta-base-biomedical-clinical-es)
- Cañete, J., Chaperon, G., Fuentes, R., Ho, J.-H., Kang, H., & Pérez, J. (2020). *Spanish pre-trained BERT model and evaluation data*. En *Practical Machine Learning for Developing Countries (PML4DC) Workshop, ICLR 2020*. <https://huggingface.co/dccuchile/bert-base-spanish-wwm-cased>
- Google. (2020). *mT5-small* [Modelo de lenguaje]. Hugging Face. [google/mt5-small](https://huggingface.co/google/mt5-small)